Traduction automatique Anglais – Darija Marocain (en Arabizi) via une Architecture Transformer

Ilias Bourhrara
Étudiant ingénieur
CentraleSupélec
Email: ilias.bourhrara@student-cs.fr

***Résumé*—Le Darija marocain est une langue descendant de l'arabe, caractérisée par l'absence d'une grammaire et d'une orthographe standardisées, rendant sa traduction automatique particulièrement complexe. Ce travail présente le développement d'un modèle de traduction automatique de type *Transformer* Anglais–Darija, optimisé sous la contrainte stricte de 100 millions de paramètres pour permettre une exécution hors ligne sur smartphone. Nous exploitons un jeu de données de 280k paires de phrases générées par distillation de *Gemini 2.5 Flash*. Pour pallier la forte variabilité lexicale du Darija, nous mettons en œuvre un *tokenizer* unique Anglais-Darija à vocabulaire partagé, couplé à une régularisation par *BPE Dropout*. Le modèle, entraîné from scratch, contient un total de 98M de paramètres. Face à l'absence de métriques *BLEU* standards adaptées aux langues non normées, l'évaluation est menée à l'aide des jugements d'un LLM, démontrant des performances remarquables face aux défis structurels de la langue.**

1. Introduction

La traduction automatique vers les langues à faibles ressources ou non standardisées représente un défi majeur pour le traitement automatique du langage naturel. Le Darija marocain (arabe marocain) s'inscrit pleinement dans cette problématique : il s'agit d'une langue essentiellement orale, caractérisée par une absence de normes grammaticales et orthographiques strictes. Habituellement écrit avec l'alphabet arabe, nous nous intéressons ici à une traduction directe en *Arabizi* (caractères latins), car une approche simple de translitération ne fonctionne pas (par exemple, la translitération traduit "voiture" – *car* en anglais – en "twmwbl" plutôt que "tomobil"). L'essentiel des ressources en ligne dans cette langue et cet alphabet est issu de communications numériques, ce qui a permis aux grands modèles de langage de bien l'assimiler.

L'objectif de ce projet est de concevoir un système de traduction Anglais vers Darija performant, tout en respectant une contrainte matérielle forte : le modèle final ne doit pas dépasser le seuil des 100 millions de paramètres, afin de garantir sa viabilité et son exécution fluide directement sur des smartphones.

2. Constitution et Normalisation du Dataset

Le principal obstacle au développement d'un modèle pour le Darija est le manque de corpus parallèles de taille suffisante, à l'exception du projet DODa, qui compte toutefois peu d'échantillons écrits en *Arabizi*.

2.1. Génération par Distillation

Pour surmonter ce manque de ressources, nous mettons en œuvre une distillation de connaissances à partir du modèle *Gemini 2.5 Flash*, qui maîtrise bien cette langue. Cette méthode a permis de générer un corpus parallèle de haute qualité comprenant environ 280K paires de phrases Anglais – Darija. Des extraits de ce jeu de données figurent en annexe. Le jeu de données a été partitionné de manière classique : **95% pour l'entraînement** et **5% pour la validation**. Ce corpus reste de taille modeste, sachant que des *datasets* de plusieurs millions de phrases sont habituellement requis pour entraîner des modèles de traduction performants.

2.2. Prétraitement et Gestion de la Séquence

La normalisation des données textuelles consiste principalement en la conversion en minuscules de l'ensemble du corpus. La longueur maximale des séquences a été fixée à **256 tokens**, ce qui s'avère généralement suffisant pour traduire des phrases du quotidien.

3. Stratégie de Tokenisation

La variabilité orthographique du Darija constitue un obstacle majeur pour les algorithmes classiques de tokenisation (ex. *bezzaf*, *bezaf* ou *bzaf* signifiant tous "beaucoup"). C'est pourquoi le *tokenizer* s'est avéré, tout au long du projet, être le principal bottleneck limitant la progression du modèle.

3.1. Limites de l'Approche Disjointe

Une première tentative reposait sur l'utilisation de deux tokenizers *BPE* distincts : un tokenizer anglais avec un vocabulaire de 32k tokens, et un tokenizer darija avec un vocabulaire de 48k tokens. Cette méthode a rapidement montré

ses limites en traitant les variantes orthographiques comme des entités totalement indépendantes. Pour illustrer, le modèle peut par exemple hésiter entre les trois orthographes *bezzaf*, *bezaf* ou *bzaf*, ce qui le mène à diluer leurs probabilités et, in fine, à générer un autre token sémantiquement déconnecté.

3.2. Optimisation par Vocabulaire Partagé et BPE Dropout

Pour résoudre ce problème, nous avons opté pour un tokenizer unique et partagé combinant l'Anglais et le Darija, avec une taille de vocabulaire restreinte à **32k tokens**. Cette approche favorise une meilleure décomposition sub-lexicale car le tokenizer, plus petit, effectue moins de merges :

$$\text{b—ez—zaf} \approx \text{b—e—zaf} \approx \text{b—zaf} \quad (1)$$

De plus, l'introduction de la technique du ***BPE Dropout*** durant l'entraînement force le modèle à s'exposer à différentes segmentations possibles pour un même mot (par exemple, alternativement `b|ez|zaf` ou `bez|zaf`), renforçant ainsi sa robustesse face aux variations d'écriture. Un exemple de segmentation du corpus est illustré ci-dessous :

```
kanbghi| nt|m|acha| f| zzna|9|i| dyal|
                l|7|ay|
```

4. Architecture du Modèle et Entraînement

Le modèle repose sur l'architecture standard du *Transformer Encoder-Decoder* mais intègre des modifications structurelles critiques pour en améliorer la convergence et l'efficacité.

4.1. Modifications Architecturales

Weight Tying : Les matrices de poids des *embeddings* d'entrée et de sortie sont partagées. Cela permet non seulement de réduire le nombre global de paramètres, mais améliore également la stabilité de l'entraînement. En effet, sans le *weight tying*, la couche linéaire de sortie a tendance, lors des premières itérations, à projeter massivement vers les tokens les plus fréquents, ce qui provoque un collapse des représentations nécessitant ensuite beaucoup de temps pour se régulariser.
Vocabulaire partagé : Le tokenizer utilisé étant commun aux deux langues, nous avons implémenté une unique matrice d'*embeddings*, partagée entre le décodeur et l'encodeur, réduisant drastiquement l'empreinte mémoire.
Pre-Layer Normalization : Contrairement à l'architecture *Post-LN* originelle, la normalisation est appliquée en amont de chaque sous-couche (*attention* et *feed-forward*) ainsi qu'en sortie de l'encodeur et du décodeur, plutôt que sur le chemin résiduel, ce qui stabilise grandement le flux des gradients.
RMSNorm : La normalisation classique par *LayerNorm* a été remplacée par la *RMSNorm*, qui démontre des performances équivalentes tout en divisant par deux le coût computationnel.

4.2. Hyperparamètres

Pour exploiter au mieux la limite de taille imposée, le modèle a été dimensionné avec les hyperparamètres présentés dans le Tableau 1.

TABLE 1. HYPERPARAMÈTRES DE L'ARCHITECTURE RETENUE

Hyperparamètre	**Valeur**
Nombre de couches Encodeur	10
Nombre de couches Décodeur	12
Dimension des *Embeddings* (d_{model})	512
Têtes d'Attention par couche (n_{head})	8
Longueur de Séquence Max	256 tokens
Total des Paramètres	**98 Millions**

Les profondeurs asymétriques de l'encodeur et du décodeur permettent de meilleures performances sur une langue aussi bruitée orthographiquement que le Darija. Un taux de *dropout* élevé (0.2) a également été appliqué dans les couches résiduelles et les matrices d'attention pour pallier la faible taille du *dataset* et limiter le surapprentissage.

4.3. Configuration de l'Entraînement

La fonction de perte utilisée est la ***Cross Entropy Loss***, configurée avec un ***Label Smoothing*** de 0.1 pour éviter que le modèle ne devienne trop confiant face aux différentes orthographes légitimes d'un même mot. L'optimisation repose sur ***AdamW*** avec un coefficient de ***Weight Decay*** de 0.01. Les gradients sont bornés via un ***Gradient Clipping*** à une norme maximale de 1.0 pour prévenir l'explosion des gradients. Enfin, un ***Learning Rate Scheduler*** combinant un *warmup* linéaire suivi d'une décroissance en ***Cosine Annealing*** a assuré une convergence optimale, avec un taux d'apprentissage maximal fixé à 4.10^{-4}.

5. Inférence

Lors de la phase d'inférence, la sélection des tokens s'appuie sur une ***Frequency Penalty*** de 0.6 afin de pénaliser les répétitions de patterns. Nous avons exploré les stratégies classiques de génération : le *Top-K sampling*, le *Top-P (Nucleus) sampling*, ainsi que le *Beam Search*, ce dernier permettant de maximiser la cohérence globale des phrases traduites. Le décodage par ***Beam Search*** couplé à la *Frequency Penalty* a finalement été retenu pour les évaluations finales.

6. Évaluation et Perspectives

L'absence de référentiels d'évaluation automatisés standards (tels que des corpus de test *BLEU* certifiés) pour le Darija constitue une limite inhérente aux langues non standardisées. Pour contourner cet obstacle, l'évaluation a été réalisée en soumettant les traductions produites par notre modèle (98M de paramètres) à un LLM externe pour vérifier leur fidélité sémantique. En l'occurrence, le modèle *Gemini*

3.5 Pro a été utilisé pour valider la fluidité et la cohérence des prédictions. Les résultats obtenus sont extrêmement prometteurs, démontrant une excellente capture des nuances de la langue et même de certaines expressions idiomatiques.

Les travaux futurs porteront en priorité sur la gestion des noms propres. S'agissant souvent de termes hors vocabulaire (absents du corpus d'entraînement), ils constituent actuellement l'une des difficultés majeures pour le modèle.

Ce travail ouvre la voie à une généralisation vers d'autres langues à orthographe et grammaire non standardisées, souffrant d'un déficit de ressources en ligne. Pour certaines de ces langues, des modèles massifs multilingues tels que *NLLB* (Meta) ou *T5* (Google) ont déjà montré des capacités remarquables qui pourraient inspirer de futures architectures compressées.

7. Annexes

7.1. Observation des embeddings entraînés

Pour visualiser l'encodage sémantique opéré par le modèle au cours de l'entraînement, une analyse en composantes principales à deux dimensions a été appliquée sur l'espace latent des *embeddings*.

La Figure 1 met en évidence la formation naturelle de clusters sémantiques regroupant les concepts par thématiques similaires, démontrant une organisation logique et structurée de l'espace de représentation.

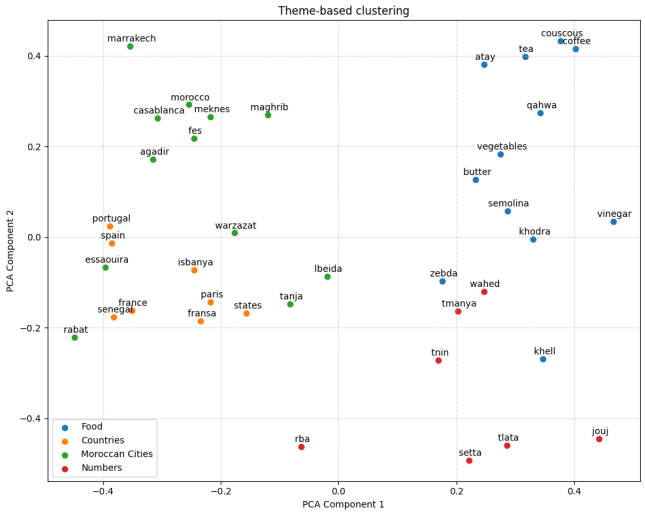


FIGURE 1. Visualisation par ACP des *clusters* thématiques au sein de l'espace d'*embeddings*.

Par ailleurs, l'alignement inter-langue a également été vérifié. Comme l'illustre la Figure 2, les projections révèlent que des concepts identiques dans les deux langues se regroupent à proximité immédiate, validant expérimentalement l'efficacité du tokenizer unique et de la stratégie de vocabulaire partagé.

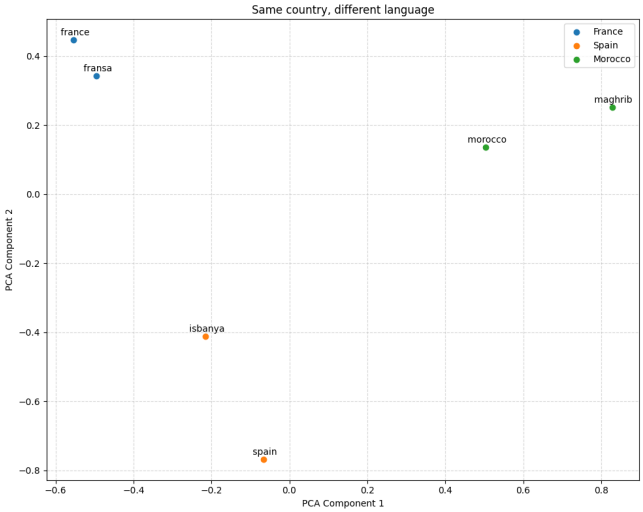


FIGURE 2. Alignement géométrique des mêmes concepts sémantiques (pays) à travers les deux langues.

7.2. Extraits du dataset

Le jeu de données construit par distillation comprend des paires de phrases de longueurs variables. Le Tableau 2, situé à la page suivante, présente des exemples d'extraits courts et longs issus du corpus parallèle Anglais – Darija.

7.3. Exemples de traduction générés

Les capacités de généralisation du modèle de 98M de paramètres ont été évaluées sur des énoncés complexes à forte charge culturelle ou contextuelle, dont certains résultats sont présentés dans le Tableau 3 à la page suivante.

TABLE 2. EXTRAITS D'EXEMPLES COURTS ET LONGS DU DATASET D'ENTRAÎNEMENT

Anglais (Source)	**Darija marocain (Cible)**
Exemples de phrases courtes	
I'm not familiar with the route to Rabat, so I'll rely on your experience. Could you ensure we take the quickest and safest way ?	Ma 3arfch triq l Rabat, dakchi 3lach ghan3tamed 3la khibrtek. Momkin tdamen liya nakhdo asra3 w a2man triq ?
My budget is limited, I can't pay more than 55 dirhams.	Lbudget diali m7doud, ma nqderch nkhallas kter men 55 dirham.
Exemple de phrase longue	
The international community's increasing recognition of the Sahara's intrinsic link to Morocco's historical and cultural identity, alongside its strategic importance for regional security and stability, means that any resolution must fully integrate the specificities of this unique region within the broader framework of Moroccan sovereignty, ensuring that the local populations are empowered to manage their affairs while remaining an integral part of the Kingdom, thus securing a peaceful and prosperous future.	L2i3tiraf lli kaykber mn lmujtama3 ddawli b rraba6 l2asassi dyal ssahra b lhowiya ttariikhiya w ttakafiya dyal lmghrib, m3a l2ahmiya listratijiya dyalha l2amn w listi9rar ljiihawi, kay3nii bali ay 7all khassu yddmaj bchakl kamil lkhousousiyat dyal had lmin6a9a lfaaridda dakhil l2i6ar l3am dyal ssiyada lmaghribiya, kayaddamman tamkin nnas lma7alliyin bach yssayro chomounhom m3a lba9a2 kjjuz2 la yatajaza2 mn lmamlakka, w bttali kayaddamman musta9bal ssalamii w raakhii.

TABLE 3. EXEMPLES DE SORTIES DE TRADUCTION OBTENUES À L'INFÉRENCE

Source	**Traduction du modèle**
Can you show me the way to the old medina ? I'm completely lost and my phone's battery is dead.	wach t9der twerini tri9 l lmedina l9dima ? ana telft kaml w tele dyali ma b9ach fih la batterie.
I spent nearly forty-five minutes this morning arguing with the merchant at the weekly souk over the price of fresh mint and orange blossom water needed for the family gathering, entirely forgetting that my grandmother expected me back hours ago to help roll the semolina grains for the Friday couscous, which meant I had to hurriedly catch a shared grand taxi under the blazing midday heat just to avoid her legendary disapproval.	dwezzt chi khamsa w arba3in dqiqa had sba7 wana kan3awd m3a lbiya3 f souq l'ousbou3i 3la taman dyal na3na3 jdid w ma zhar li khasso l jam3a dyal la famille, nssit ga3 belli jaddati kant katssennani men qbel swaye3 bach n3awen ndawwer 7boub smida l couscous dyal nhar ljomu3, dakchi li khasni khassni nchadd taxi kbir mouchtarak ta7t skhouna dyal nos nhar ghir bach netfadda rafdha l'os6ori.