Traduction automatique Anglais – Darija Marocain (en Arabizi) via une Architecture Transformer

Ilias Bourhrara
Étudiant ingénieur
CentraleSupélec
Email: ilias.bourhrara@student-cs.fr

***Résumé*—Le Darija marocain est une langue descendant de l'arabe caractérisée par l'absence d'une grammaire et d'une orthographe standardisées, rendant sa traduction automatique particulièrement complexe. Ce travail présente le développement d'un modèle de traduction automatique de type Transformer Anglais–Darija, optimisé sous la contrainte stricte de 100 millions de paramètres pour permettre une exécution hors ligne sur smartphone. Nous exploitons un jeu de données de 280k paires de phrases générées par distillation de Gemini 2.5 Flash. Pour pallier la forte variabilité lexicale du Darija, nous mettons en œuvre un tokenizer unique Anglais-Darija à vocabulaire partagé (32k) couplé à une régularisation par BPE Dropout. L'architecture intègre le liage des poids (Weight Tying) et la normalisation Pre-Layer, atteignant un total de 98M de paramètres. Face à l'absence de métriques BLEU standards adaptées aux langues non normées, l'évaluation est menée via une approche de LLM-as-a-judge, démontrant des performances remarquables face aux défis structurels de la langue.**

1. Introduction

La traduction automatique vers les langues à faibles ressources ou non standardisées représente un défi majeur pour le traitement automatique du langage naturel. Le Darija marocain (arabe marocain) s'inscrit pleinement dans cette problématique : il s'agit d'une langue essentiellement orale, caractérisée par une absence de normes grammaticales et orthographiques strictes. Habituellement écrit avec l'alphabet arabe, nous nous intéressons à une traduction directe en Arabizi (caractères latins) car une approche simple de translitération ne fonctionne pas (Ex : la translitération traduit "voiture" ('car' en anglais) en "twmwbl" plutôt que "tomobil"). L'essentiel des ressources en ligne dans cette langue et cet alphabet sont issues de communications numériques, ayant permis aux grands modèles de langage de bien l'assimiler.

L'objectif de ce projet est de concevoir un système de traduction Anglais vers Darija performant, tout en respectant une contrainte matérielle forte : le modèle final ne doit pas dépasser le seuil des 100 millions de paramètres afin de garantir sa viabilité et son exécution fluide directement sur des smartphones.

2. Constitution et Normalisation du Dataset

L'un des principaux verrous du développement de modèles pour le Darija est l'indisponibilité de corpus parallèles de taille suffisante, si ce n'est le projet DODa mais qui compte peu de samples écrits en Arabizi.

2.1. Génération par Distillation

Pour surmonter ce manque de ressources, j'ai mis en œuvre une stratégie de distillation de connaissances à partir du modèle de pointe `Gemini 2.5 Flash` qui écrit dans cette langue de manière très correcte. Cette méthode a permis de générer un corpus parallèle de haute qualité comprenant environ 280 000 paires de phrases Anglais – Darija pour un coût de revient optimisé d'environ 70 euros. Des exemples du jeu de données figurent en annexe. Le jeu de données a été partitionné de manière classique : 95% pour l'entraînement et 5% pour la validation. Le corpus est de taille modeste, puisque des datasets de plusieurs millions de phrases sont habituellement utilisés.

2.2. Prétraitement et Gestion de la Séquence

La normalisation des données textuelles s'est concentrée sur la mise en minuscules systématique de l'ensemble du corpus. Compte tenu de la structure morphosyntaxique des phrases générées, la longueur maximale des séquences a été fixée à 256 tokens, ce qui est généralement suffisant pour traduire des phrases du quotidien.

3. Stratégie de Tokenisation

La variabilité orthographique du Darija constitue un obstacle majeur pour les algorithmes classiques de tokenisation (ex. *bezzaf*, *bezaf* ou *bzaf* signifiant tous "beaucoup"). Le Tokenizer s'est avéré, tout au long du projet, être le principal bottleneck à la progression du modèle.

3.1. Limites de l'Approche Disjointe

Une première tentative reposait sur l'utilisation de deux tokenizers BPE (Byte Pair Encoding) distincts : un sous-corpus anglais avec un vocabulaire de 32k tokens, et un

sous-corpus darija avec un vocabulaire de 48k tokens. Cette méthode a montré ses limites en traitant les variantes orthographiques comme des entités totalement indépendantes, fragmentant ainsi l'espace sémantique. Pour illustrer, le modèle peut par exemple hésiter entre les trois orthographes *bezzaf*, *bezaf* ou *bzaf*, ce qui le mène à diluer leurs probabilités et à finalement préférer un autre token non adéquat.

3.2. Optimisation par Vocabulaire Partagé et BPE Dropout

Pour résoudre ce problème, j'ai opté pour un tokenizer unique et partagé combinant l'Anglais et le Darija avec une taille de vocabulaire restreinte à 32k tokens. Cette approche unifiée favorise une meilleure décomposition sub-lexicale :

$$\text{b—ez—zaf} \approx \text{b—e—zaf} \approx \text{b—zaf} \quad (1)$$

De plus, l'introduction de la technique du *BPE Dropout* durant l'entraînement permet de forcer le modèle à voir différentes segmentations possibles pour un même mot (par exemple alternativement `b|ez|zaf` ou `bez|zaf`), renforçant ainsi la robustesse du modèle face aux variations d'écriture. Un exemple de segmentation du corpus est illustré ci-dessous :

```
kanbghi| nt|m|acha| f| zzna|9|i| dyal|
                l|7|ay|
```

4. Architecture du Modèle et Entraînement

Le modèle repose sur l'architecture standard du Transformer Encoder-Decoder mais intègre des modifications structurelles critiques pour en améliorer la convergence et l'efficacité.

4.1. Modifications Architecturales

Weight Tying (Liaison des poids) : Les matrices de poids des embeddings d'entrée et de sortie sont partagées. Cela permet non seulement de réduire le nombre global de paramètres, mais améliore également la stabilité de l'entraînement. En effet, sans le weight tying, la couche linéaire de sortie semble, dans les premières itérations de l'entraînement, projeter en masse vers les tokens communs (comme les mots "le", "la", "et" en français par exemple), ce qui provoque un collapse qui met ensuite du temps à se régulariser.

Pre-Layer Normalization (Pre-LN) : Contrairement à l'architecture Post-LN originelle, la normalisation est appliquée en amont de chaque sous-couche (attention et feed-forward) ainsi qu'en sortie de l'encodeur et du décodeur plutôt que sur le chemin résiduel, ce qui stabilise les gradients.

4.2. Hyperparamètres

Pour exploiter au mieux la limite de taille imposée, le modèle a été dimensionné avec les hyperparamètres présentés dans le Tableau 1.

TABLE 1. HYPERPARAMÈTRES DE L'ARCHITECTURE RETENUE

Hyperparamètre	**Valeur Configuration**
Nombre de couches Encodeur	10
Nombre de couches Décodeur	12
Dimension des Embeddings (d_{model})	512
Têtes d'Attention par couche (n_{head})	8
Longueur de Séquence Max	256 tokens
Total des Paramètres	**98 Millions**

Les profondeurs de l'encodeur et du décodeur permettent de meilleures performances sur une langue aussi bruitée en orthographe que le Darija. Un dropout élevé (0.2) a aussi été utilisé dans les couches résiduelles et dans les matrices d'attention, pour pallier la faible taille du dataset.

4.3. Configuration de l'Entraînement

La fonction de coût utilisée est la *Cross Entropy Loss* configurée avec un lissage de label (*Label Smoothing*) de 0.1 pour éviter la confusion du modèle vis-à-vis des différentes orthographes d'un même mot. L'optimisation adopte l'algorithme `AdamW` associé à un coefficient de *Weight Decay* de 0.01. Les gradients sont contraints via du *Gradient Clipping* à une norme maximale de 1.0 pour éviter des explosions de gradient. Un *Learning Rate Scheduler* avec un warmup linéaire suivi d'une décroissance Cosine Annealing a permis la convergence optimale.

5. Inférence

Lors de l'inférence, la sélection des tokens s'appuie sur une pénalité de fréquence (*Frequency Penalty = 0.6*) afin d'éviter les répétitions de patterns, combinée à une exploration des stratégies classiques de décodage : le *Top-K sampling*, le *Top-P (Nucleus) sampling*, ainsi que le (*Beam Search*) pour maximiser la cohérence globale des phrases traduites. Le décodage par Beam Search couplé avec la Frequency Penalty a été retenu pour les évaluations finales.

6. Évaluation et Perspectives

L'absence de référentiels d'évaluation automatisés standards (tels que des tests BLEU validés) pour le Darija constitue une limite inhérente aux langues non standardisées. Pour contourner cette limite, l'évaluation a été réalisée en adoptant la méthodologie moderne du *LLM-as-a-judge*, où un modèle de langage de large taille évalue qualitativement et s'assure de la fidélité sémantique des traductions produites par notre modèle de 98M de paramètres. En l'occurence le modèle Gemini 3.5 Pro a été utilisé pour valider la cohérence des prédictions. Les résultats préliminaires s'avèrent extrêmement prometteurs, montrant une excellente capture des idiotismes locaux.

Les travaux futurs se pencheront sur la gestion des noms propres, car ce sont souvent des mots qui n'ont pas été vus dans le dataset et donc avec lesquels le modèle a du mal.

Ce travail peut se généraliser à d'autres langues à orthographe et grammaire non standardisés, et à faible ressources en ligne. Pour certaines de ces langues, des modèles tels que les *NLLB* de Meta ou les *T5* de Google montrent des résultats remarquables.

7. Annexes

7.1. Observation des embeddings entraînés

Pour valider l'alignement sémantique opéré par le modèle au cours de l'entraînement, une analyse en composantes principales (ACP) à deux dimensions a été appliquée sur l'espace des plongements vectoriels (embeddings).

La Figure 1 met en évidence la formation naturelle de clusters sémantiques regroupant les concepts par thématiques similaires, démontrant une organisation logique de l'espace latent.

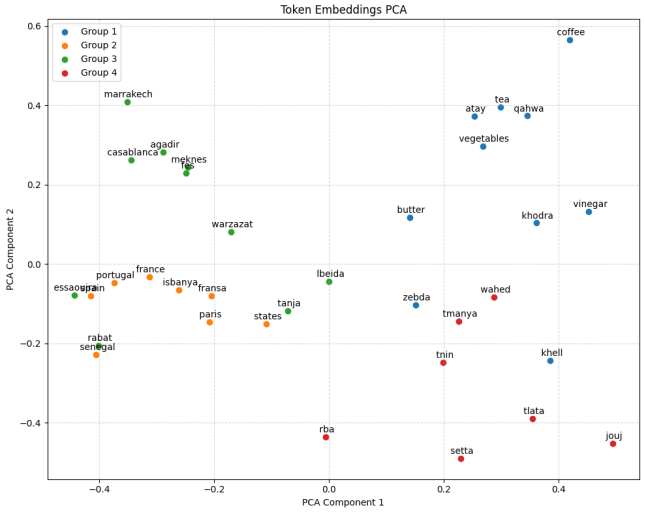


FIGURE 1. Visualisation par ACP des clusters thématiques au sein de l'espace d'embeddings.

Par ailleurs, l'alignement inter-langue a été vérifié de manière géométrique. Comme l'illustre la Figure 2, les projections révèlent que les entités nommées partagées (comme les noms de pays) se regroupent à proximité immédiate dans les deux langues, confirmant l'efficacité du tokenizer unique et de la stratégie de vocabulaire partagé.

7.2. Extraits du dataset

Le jeu de données construit par distillation comprend des paires de phrases de longueurs variables. Le Tableau 2 présente des exemples d'extraits courts et longs issus du corpus parallèle Anglais – Darija.

7.3. Exemples de traduction générés

Les capacités de généralisation du modèle de 98M de paramètres sont évaluées sur des énoncés complexes à forte charge culturelle ou contextuelle (Tableau 3).

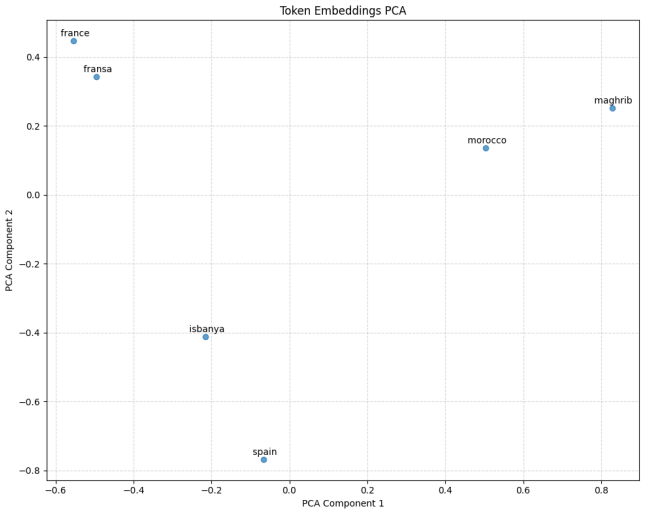


FIGURE 2. Alignement géométrique des mêmes concepts sémantiques (pays) à travers les deux langues.

TABLE 2. EXTRAITS D'EXEMPLES COURTS ET LONGS DU DATASET D'ENTRAÎNEMENT

Anglais (Source)	**Darija marocain (Cible)**
Exemples de phrases courtes	
I'm not familiar with the route to Rabat, so I'll rely on your experience. Could you ensure we take the quickest and safest way ?	Ma 3arfch triq l Rabat, dakchi 3lach ghan3tamed 3la khibrtek. Momkin tdamen liya nakhdo asra3 w a2man triq ?
My budget is limited, I can't pay more than 55 dirhams.	Lbudget diali m7doud, ma nqderch nkhallas kter men 55 dirham.
Exemple de phrase longue	
The international community's increasing recognition of the Sahara's intrinsic link to Morocco's historical and cultural identity, alongside its strategic importance for regional security and stability, means that any resolution must fully integrate the specificities of this unique region within the broader framework of Moroccan sovereignty, ensuring that the local populations are empowered to manage their affairs while remaining an integral part of the Kingdom, thus securing a peaceful and prosperous future.	L2i3tiraf lli kaykber mn lmujtama3 ddawli b rraba6 l2asassi dyal ssahra b lhowiya ttariikhiya w ttakafiya dyal lmghrib, m3a l2ahmiya listratijiya dyalha l2amn w listi9rar ljiihawi, kay3nii bali ay 7all khassu yddmaj bchakl kamil lkhousousiyat dyal had lmin6a9a lfaaridda dakhil l2i6ar l3am dyal ssiyada lmaghribiya, kayaddamman tamkin nnas lma7alliyin bach yssayro chomounhom m3a lba9a2 kjjuz2 la yatajaza2 mn lmamlakka, w bttali kayaddamman musta9bal ssalamii w raakhii.

TABLE 3. EXEMPLES DE SORTIES DE TRADUCTION OBTENUES À L'INFÉRENCE

Source	**Traduction du modèle**
Can you show me the way to the old medina ? I'm completely lost and my phone's battery is dead.	wach t9der twerini tri9 l lmedina l9dima ? ana telft kaml w tele dyali ma b9ach fih la batterie.
I spent nearly forty-five minutes this morning arguing with the merchant at the weekly souk over the price of fresh mint and orange blossom water needed for the family gathering, entirely forgetting that my grandmother expected me back hours ago to help roll the semolina grains for the Friday couscous, which meant I had to hurriedly catch a shared grand taxi under the blazing midday heat just to avoid her legendary disapproval.	dwezzt chi khamsa w arba3in dqiqa had sba7 wana kan3awd m3a lbiya3 f souq l'ousbou3i 3la taman dyal na3na3 jdid w ma zhar li khasso l jam3a dyal la famille, nssit ga3 belli jaddati kant katssennani men qbel swaye3 bach n3awen ndawwer 7boub smida l couscous dyal nhar ljomu3, dakchi li khasni khassni nchadd taxi kbir mouchtarak ta7t skhouna dyal nos nhar ghir bach netfadda rafdha l'os6ori.